

AI 网站完整成本分析与降本方案

适用于文本生成 知识问答 文档处理及其扩展业务

编制日期 2026年9月13日

本报告用于确定 AI 网站从开发到持续经营需要准备多少资金，以及哪些优化最值得先做。基准产品采用现成大模型 API，包含账号、额度、支付、管理后台和基础文档问答；图片、视频、复杂智能体与企业私有化另行测算。

核心判断：早期先控制开发范围与持续人力，中期优化每个成功任务的成本，增长期重点约束免费补贴和获客成本。服务器费用只是完整经营成本的一部分。

在本文的透明假设下，1,000、1万、10万月活用户对应的月度技术成本约为 **1,052元、7,522元、67,218元**；加上规划中的人力、增长和行政费用，并为技术支出留20%缓冲后，月度资金预算约为 **1.16万元、5.00万元、24.57万元**。这些是同一文本产品的情景演算，不是按用户数承诺的市场报价；支付、税费和特殊合规支出需按实际情况追加。

最有价值的降本动作通常是：限定首版功能；按难度选择模型；减少无用上下文与过长输出；约束重试和智能体循环；设置服务端预算及免费额度；用成功率、留存和贡献利润验证效果。缓存与自部署应在有真实用量数据后决定。

阅读导航

先阅读第6节预算和第9至10节降本方案；第5节提供计算口径，第8节检验商业模式。目录页码与PDF书签均可用于定位。

1 分析范围与预算口径	3
2 全生命周期成本清单	4
3 开发建设需要多少投入	5
4 官方价格参照与使用边界	5
5 任务成本怎样计算	7
6 三个规模的完整月度预算	8
7 哪些变量最容易让预算失真	10
8 免费用户和定价是否能覆盖成本	10
9 降本优化的优先级	11
10 一个完整的降本演算	13
11 不同类型 AI 网站的额外成本	14
12 API 和自部署怎样选择	15
13 中国与海外业务的成本差异	16
14 成本监控和预算控制	17
15 三十天实施计划	17
16 可直接复用的预算输入清单	18
17 官方来源与核价说明	19

1 分析范围与预算口径

基准业务

基准是一款订阅制文本 AI 网站。用户可聊天、生成内容、提交文档问题；后端调用模型完成任务，保存必要的会话和文件。网站不自行训练基础大模型，不默认自购 GPU，不假设无限上下文、无限免费额度或全天人工客服。

本报告同时覆盖面向中国用户和海外用户的成本差异。美元模型和海外基础设施用于提供可复算的价格参照；境内模型另列人民币峰谷演算。不同供应商即使 token 相同，也未必具有相同质量、速度、地区可用性和合同条件，不能据此直接认定谁最适合业务。

三种数字必须分开

数字类型	用途	本报告处理方式
官方公开价格	了解服务计费规则	标明型号、币种、单位、来源及核查日期
项目规划假设	估算人力、使用频率、转化率与资源	明确假设，可用实际数据替换，不声称市场均价
公式计算结果	得出月成本、毛利、回收期	由已列输入推导，展示中四舍五入，合计用未舍入值

统一展示人民币。美元换算统一假设 **1美元 = 7.00元人民币**，仅用于预算演算，不代表当日即期或结算汇率。模型比较默认标准处理、所列上下文档位、无额外工具；优惠、赠额、特殊区域溢价、税费及汇兑手续费不默认为零成本。

四张账的用途

现金支出表反映实际付款时间；年度云服务预付要计入付款月份。服务交付成本包括模型、基础设施、支付以及交付相关支持人力，用于管理口径毛利。完整经营成本再计入持续研发、增长、行政和负责人劳动。一次性建设投入单列，用于资金计划。

创始人领工资可以减少当期现金支出，但仍应记录劳动的替代成本。将建设投入按12个月分摊可以帮助内部比较方案，却不能在首年现金预算中同时计入全部投入和同一笔摊销。会计和税务处理需依据实际主体与合同确定。

2 全生命周期成本清单

一次性建设投入

成本项目	包含内容	最有效的控制方式
产品与交互设计	需求、流程、原型、页面和文案	先做一个可收费的核心流程，统一验收标准
前后端开发	用户、任务、文件、支付、额度、后台	使用成熟组件，减少首版自定义基础功能
AI 工程	提示词、模型接入、路由、RAG、评估	先建立评估集，再增加模型与智能体复杂度
数据准备	清洗、去重、OCR、授权、初始索引	先抽样评估数据质量，按增量导入
上线验证	测试、支付对账、负载、权限、恢复	明确正常和异常流程，不只测试演示路径
商业与上线准备	域名、主体、协议、品牌、安全或合规核查	按地区与业务适用性预算，避免重复购买

持续经营投入

成本域	计费或投入驱动	常见遗漏
模型与工具	输入、输出、缓存、联网、OCR、沙箱	历史反复输入、内部多轮、推理消耗、失败重试
应用计算	请求、CPU时间、实例、并发、运行时长	流式长连接、冷启动、负载均衡、固定IP
数据与网络	数据库、对象存储、操作次数、出网	索引、备份、跨区、NAT、重复下载
认证与消息	活跃用户、短信、邮件、验证码	刷注册、短信轰炸、投递失败重发
观测与安全	日志量、保留期、告警、WAF、审计	完整提示词日志、预览环境、异常流量
客服与内容治理	工单量、审核量、退款、知识库维护	高价值客户专属支持、节假日值班
持续研发	迭代、修复、模型变更、质量评估	已停用模型迁移、兼容维护、技术债
增长与行政	广告、内容、销售、财务、办公	未转化流量、销售佣金、渠道抽成
收款与税费	交易额、笔数、退款、地区、主体	固定交易费、争议费、汇差、间接税

风险成本和退出成本

给 API Key 泄漏、异常重试、热门活动、供应商故障和资源迁移留出资金空间。备用模型会引入评估、维护和更高价格，不宜只记作“切换开关”。对数据导出、索引重建、域名续费、删除请求以及停服退款，也应明确负责人和处理成本。

风险准备金是预算缓冲，不是已经发生的费用。本文情景表只对技术支出增加20%缓冲；不代表能覆盖所有故障或人员风险，企业客户的 SLA 和高成本多媒体业务需要单独压力测试。

3 开发建设需要多少投入

按工作量估算

以下为规划区间，综合人月单价含薪酬、协作和用工等预算因素，不是招聘统计或外包报价。应根据功能清单向执行团队索取分项报价。

产品范围	规划工作量	综合成本假设	建设人力预算
验证型 MVP	2至4人月	2至4万元 / 人月	4至16万元
可收费商业版	5至10人月	3至5万元 / 人月	15至50万元
企业或复杂产品	12至30人月	4至7万元 / 人月	48至210万元

MVP 包含单一核心功能、账号、额度、基础支付和管理；商业版增加文档处理、对账、质量评估和异常恢复；企业版增加多租户、权限审计、系统集成与服务承诺。各档功能深度不同，不能只按页面数量比较报价。

人月不等于工期。两人完成5人月工作，不一定恰好需要2.5个月，外部接口、资料准备和验收都可能影响周期。AI 编程工具能减少部分编码时间，不能直接消除产品判断、权限隔离、支付验证和后续维护。

自己开发与外包怎样比较

自己开发时，建议同时记录“已付现金”和“投入工时乘替代时薪”。例如创始人投入240小时、替代时薪假设200元，劳动成本为4.8万元；额外购买工具、设计和测试服务3,000元，则现金支出可能较低，但完整建设成本为5.1万元。该例为计算演示，不保证240小时可以完成任意商业版。

外包报价要明确是否包含源代码、云账号归属、支付对账、部署、文档、数据导出、验收、缺陷修复和维护期。按演示页面验收，可能把补做计费、权限和安全的费用推迟到上线以后。对报价差异应先检查交付范围，再比较单价。

首版最值得删减的范围

首版优先保留一条用户愿意付费的流程。多模型选择面板、复杂会员等级、插件市场、团队协作、多语言后台、无限历史和自建向量平台，应有明确需求后再加入。多个模型都需要评估、计量、故障处理和升级维护，接入数量本身不等于产品价值。

不宜从首版删掉服务端额度、最基本的权限隔离、支付幂等、错误监控和可恢复备份；这些缺失容易直接形成超额账单、退款和返工。

4 官方价格参照与使用边界

公开价格核查于2026年9月13日。下表为选定服务的价格快照；实际付款取决于账号、地区、档位、用量和购买时条款。所有美元价格保留原币，不将不同功能的套餐直接相加为唯一推荐架构。

文本模型

供应商与模型	普通输入	缓存读取	输出	单位和条件
OpenAI GPT 5.6 Luna	\$0.20	\$0.02	\$1.20	美元 / 百万token，标准短上下文 [S1]
OpenAI GPT 5.6 Terra	\$2.00	\$0.20	\$12.00	美元 / 百万token，标准短上下文 [S2]
DeepSeek V4.1 Flash 空闲	¥1.00	¥0.02	¥4.00	人民币 / 百万token [S3]
DeepSeek V4.1 Flash 高峰	¥2.00	¥0.04	¥8.00	人民币 / 百万token [S3]
DeepSeek V4 Pro 0813 空闲	¥4.50	¥0.15	¥13.50	人民币 / 百万token [S3]
DeepSeek V4 Pro 0813 高峰	¥9.00	¥0.30	¥27.00	人民币 / 百万token [S3]
Claude Haiku 4.5	\$1.00	\$0.10	\$5.00	美元 / 百万token，标准处理 [S4]
Claude Sonnet 5	\$2.00	\$0.20	\$10.00	美元 / 百万token，标准处理 [S4]

DeepSeek 高峰为北京时间周一至周五9至12时及14至18时，其余为空闲。请求模型标识分别为 deepseek-flash 和 deepseek-v4-pro；不要把旧型号或旧网页价格混入预算。[S3]

GPT 5.6 的缓存写入单价为普通输入的1.25倍；长上下文、区域处理和其他服务档位要另按价格页确认。[S1][S2][S5] Claude 的5分钟缓存写入为1.25倍、1小时写入为2倍普通输入价。[S4] 缓存读取价格不能套用到所有输入 token，更不能直接理解为整站成本打同样折扣。

基础设施和支付

服务	公开价格参照	主要附加条件
Cloudflare Workers Paid	最低\$5 / 账户 / 月	含1,000万请求及3,000万CPU毫秒；超额分别\$0.30 / 百万请求、\$0.02 / 百万CPU毫秒 [S11]
Cloudflare R2 标准存储	\$0.015 / GB月	每月10GB月免费；A类\$4.50 / 百万次、B类\$0.36 / 百万次，分别有100万和1,000万次免费；互联网出网免费 [S12]
Supabase Pro	从\$25 / 组织 / 月	含\$10计算抵扣，可覆盖一个Micro；更多项目、计算、容量和出网另计 [S13]
Vercel Pro	\$20 / 月平台费	含一个部署席位及\$20用量抵扣，额外部署席位\$20 / 人 / 月，用量超额另计 [S14]
Stripe美国国内卡线上支付	2.9% + \$0.30 / 成功交易	国际卡额外1.5%，需币种转换再加1%；此为美国账户示例 [S15]

Workers的CPU时间与等待模型API返回的墙钟时间不同，且它不替代GPU推理服务器。[S11] R2的免费出网不代表读取请求或所有相关产品免费。[S12] Vercel的\$20抵扣不是再从\$20平台费中扣掉一次；商业用途还应确认套餐条款。[S14]

Stripe的固定每笔费会放大小额收款成本：\$5订单基础手续费\$0.445，占8.9%；\$20订单为\$0.88，占4.4%。订阅账单、税务服务、退款与争议等按产品和账号另算，不能把上述费率套用到中国大陆主体或所有地区。[S15]

服务可替代也可组合。例如海外轻量架构可使用一个应用托管平台、一个数据库服务和对象存储；无需为相同的前端托管能力同时购买多套平台。定价中的 MAU、请求数、CPU时间、数据库容量、出网量和团队席位各自独立，月活少也可能因为长时间任务或大文件产生超额费用。

域名建议按普通非溢价域名每年80至200元做规划占位，并查看续费价；HTTPS 可优先使用托管平台或自动签发的免费证书，商业要求另论。上述域名区间是预算假设，不是所有后缀的报价。

5 任务成本怎样计算

从用户任务到供应商账单

月任务数 = 月活用户数 × 实际使用AI的比例 × 每位使用者每月任务数。 月活指访问或使用产品的用户，实际建模时需确认口径；本文规模情景假设所列月活都使用AI，平均每人20个任务。

月模型费 = 各类任务数 × 各类任务全部模型调用的平均成本，再按类型求和。 每次调用分别计算普通输入、缓存读取、缓存写入和输出 token，并加上工具等独立费用。token 是模型计费单位，不等于汉字数或英文单词数；应使用供应商返回的 usage 数据校准。

模型普通调用成本的简化计算为：输入token数÷1,000,000×输入单价，加输出token数÷1,000,000×输出单价。若存在缓存，应把输入拆成互不重叠的普通输入、读取和写入部分，分别使用对应单价，不能重复计数。

系统提示、历史消息、检索片段、工具响应、图像输入和适用的推理 token 都可能进入计费。流式输出可以改善等待体验，但不自动减少 token。用户关闭网页后后端若继续运行，费用仍可能继续产生。

基准任务的可复算演算

参数	本文基准假设
首次模型调用平均输入	2,000 token，包含系统、历史和必要检索片段
每次调用平均计费输出	800 token，包含计费的推理输出等消耗
模型分配	85% Luna，15% Terra，按调用分配且各模型使用相同均值
平均调用放大系数	每个发起任务1.10次，含额外调用与重试
缓存读写	基准均按0演算且不使用可缓存前缀；实际自动写入或命中需替换计费量
额外变量费	每个任务0.003元，为检索、治理等轻量开销的规划占位
汇率	7.00元 / 美元，预算假设

混合输入价格 = (85%×0.20 + 15%×2.00)×7 = 3.29元 / 百万token。混合输出价格 = (85%×1.20 + 15%×12.00)×7 = 19.74元 / 百万token。[S1][S2]

每次调用 = (2,000×3.29 + 800×19.74)÷1,000,000 = 0.022372元。每个发起任务模型费 = 0.022372×1.10 = 0.0246092元；再加0.003元辅助费，每任务变量成本约0.0276092元。

85%与15%是互斥分流，不是先跑小模型再升级；若增加模型分类器、摘要或先小后大的流程，要加入它们的额外费用。复杂任务往往更长，正式预算应分别统计每种模型的输入输出，不能持续沿用相同均值。

成功率与容量

上述单价以“发起任务”为分母。**每成功任务成本 = 包括失败和取消在内的相关总成本 ÷ 成功任务数**。假设95%任务成功，则模型费 $0.0246092 \div 95\% \approx 0.02590$ 元 / 成功任务；未成功的支出没有消失。若日志已经包含全部重试，禁止再次乘1.10。

月账单取决于总用量，服务容量取决于峰值。200,000任务 / 月按30天计算仅约0.077任务 / 秒，若峰值达到平均的30倍，则约2.31任务 / 秒；处理平均20秒时约46个在途任务。该例不含额外排队，仍需检验供应商请求限速、token限速、长连接、数据库连接及上传峰值。

6 三个规模的完整月度预算

基准情景

以下为规划演算，三档使用相同任务结构。基础设施和人力随阶段采用不同占位预算，均需负载验证或报价确认。技术成本包括模型、辅助变量费用及固定基础设施；持续人力含技术维护、迭代和支持的合并成本，不再在其他行重复计算相同员工。

项目 每月人民币	1,000月活	1万月活	10万月活
发起任务数	20,000	200,000	2,000,000
模型API	492	4,922	49,218
辅助变量费	60	600	6,000
固定基础设施	500	2,000	12,000
技术成本小计	1,052	7,522	67,218
持续人力	8,000	30,000	100,000
增长与内容预算	2,000	10,000	60,000
行政与基础管理	300	1,000	5,000
完整经营成本	11,352	48,522	232,218
技术成本20%缓冲	210	1,504	13,444
月度资金预算	11,563	50,026	245,662

1万月活情景的完整经营成本结构



- 模型与辅助 11.4%
- 基础设施 4.1%
- 持续人力 61.8%
- 增长与内容 20.6%
- 行政 2.1%

规划演算 不含支付税费与风险缓冲 月经营成本约48,522元

该表没有假设收入，支付手续费按实际交易额和笔数追加；税费、特定许可评估、企业专属交付、媒体生成、重型联网搜索和大规模OCR也不包含在0.003元占位费内。固定基础设施预算包括应用、数据库、对象存储、基础监控和备份的合并占位；第4节套餐是报价参照，不能再整套重复加到此表。

1,000月活情景若由创始人承担8,000元劳动且暂不支付，其月现金预算约3,563元；完整劳动成本仍为11,563元的预算口径。自有电脑、域名预付和支付费应另按实际现金流入账。

1万月活情景中，模型费约占未加缓冲完整经营成本的10.1%，持续人力占61.8%。即使把模型费降低一半，也只节省约2,461元 / 月，约为完整经营成本的5.1%；产品范围和团队效率仍十分关键。

基础设施占位预算怎样拆开

合并预算内容	验证期	商业初期	增长期
前端与应用计算	150	500	3,000
数据库与缓存	200	700	4,000
对象存储与网络	50	300	2,000
监控 备份 消息等	100	500	3,000
合计 元 / 月	500	2,000	12,000

这些是配置规划额度，不对应某个套餐的无限资源承诺。数据库连接和存储增长、图片视频出网、日志量、跨区通信及冗余需求都可能突破额度；正式采购应把每项用量填入服务商计算器。

境内模型对照

用同样的200,000任务、2,000输入、800输出、1.10次调用，以及85% Flash / 15% Pro占比计算：DeepSeek 全部按空闲价约 **1,626元 / 月**，全部按高峰价约 **3,252元 / 月**。美元模型基准约 **4,922元 / 月**。
[S3] 这些仅比较模型费用，质量、token切分、重试与延迟需要实测。

实际混合账单应分别统计峰谷的计费 token，不按时段长度直接平均价格。文本即时回答通常不能为了省钱强制等到空闲时段；允许延迟的数据清洗、内容批量生成和索引更新可评估错峰。

上线后首年和六个月资金

下表假设上线后维持对应规模，建设投入只记一次；未抵扣任何收入、融资或税费抵扣。不是用户增长预测，也不是净现金消耗预测。这里的首年指上线后的12个月，不是自立项起的自然年度。

项目	验证型	商业初期	增长期配置
建设投入假设	5万元	18万元	60万元
六个月运营加建设	11.94万元	48.02万元	207.40万元
首年运营加建设	18.88万元	78.03万元	354.79万元

计算为建设投入加月度资金预算乘6或12。建设期间额外运营支出、开发超期、账期、供应商预充值和年费预付需另排现金计划。预付年费改善优惠时，也会提前占用现金。

7 哪些变量最容易让预算失真

单因素敏感性

保持1万月活基准其余条件不变，每次只改变一项：

变化	月模型费 元	相对基准
基准	4,922	1.00倍
每人月任务20增至40	9,844	2.00倍
每任务调用1.10增至2.00	8,949	1.82倍
平均输入2,000增至10,000	10,712	2.18倍
平均输出800增至2,400	11,870	2.41倍
较高价模型占比15%增至50%	11,519	2.34倍

平均值还会隐藏少数高成本用户。每个套餐至少查看任务成本的P50、P95、P99、最大值，以及成本最高1%用户的费用占比。长文档、智能体、图片和视频应单独统计，避免用低价聊天的均值补贴昂贵功能。

三种预算情景

最低合理预算应包含已确定的固定支出和可控免费额度。基准预算使用近期真实均值。压力预算组合检验较高价模型回退、流量激增、重复任务、长输出、缓存失效和出网增长。

若任务量翻倍且每任务输出也增至3倍，不能只选敏感性表其中一行；应重新计算所有变化。即使供应商预算提醒已发出，在途任务和延迟结算也可能使实际金额继续增加。

8 免费用户和定价是否能覆盖成本

先看每位用户的贡献

本节采用独立的用户分组例子：1万月活、3%付费、套餐49元 / 月，付费者100任务 / 月，免费者20任务 / 月。支付费率用1%作为规划占位，并非某个支付服务的报价；假设无折扣退款，暂不计算税费。

每任务变量成本仍取0.0276092元，因此付费用户变量消耗约2.76元，免费用户约0.5522元。付费用户扣支付费和自身任务变量费后的贡献约45.75元。该例共224,000任务，与第6节的200,000任务不同，因为此处显式区分了两类用户。

月度项目	计算	结果 元
套餐收入	300×49	14,700
支付费	$14,700 \times 1\%$	147
付费任务变量费	$300 \times 100 \times 0.0276092$	828
免费任务变量费	$9,700 \times 20 \times 0.0276092$	5,356
扣变量费后贡献	收入减上述费用	8,369

月度项目	计算	结果 元
固定经营支出	2,000设施 + 30,000人力 + 10,000增长 + 1,000行政	43,000
月经营结果	贡献减固定支出	亏损34,631

尽管付费用户本人的任务消耗很低，免费补贴与固定经营成本仍会造成亏损。本例的贡献金额未扣固定交付成本，不应直接标成财务毛利。

盈亏平衡必须声明增长假设

每月每MAU贡献 = 付费率 × 付费用户贡献 - 免费比例 × 免费用户成本。本例为0.83685392元。若使用结构、定价、转化率和43,000元固定支出都不变，数学上的盈亏平衡点约51,383月活；实际增长通常会增加人力、设施和获客支出，因此这不是保证盈利的规模。

保持1万月活与相同固定支出，所需付费率约10.48%。如果只要求总变量贡献为正、尚不覆盖固定成本，最低付费率约1.19%。如果免费用户提高调用量或收费用户使用昂贵模型，这两个阈值都会改变。

免费额度和套餐设计

先决定每个免费活跃用户可承受的月补贴，再除以对应任务的变量成本，得到额度上限。0.50元补贴预算在本例可支持约18个普通任务；这是预算上限演示，还要扣除认证、支持等其他免费用户成本。

适合采用基础订阅加明确额度，对图片、视频、长文档和复杂智能体单独扣积分或按量收费。积分需映射到各功能的成本，不宜把一段视频和一条普通问答都算成“1次”。对失败、部分完成和取消任务应定义用户计费与供应商成本的差额处理。

获客成本和现金回收

$CAC = \text{可归因的获客费用} \div \text{新增付费客户数}$ 。广告、内容制作、渠道佣金和销售人力需按一致口径计算，不能只看点击成本。举例投入10,000元新增100位付费客户，CAC为100元；若每位新增客户扣可变交付和服务成本后的月贡献40元，未考虑流失的回收期为2.5个月。

应用真实客户批次的3个月、6个月、12个月累计贡献检查回本；短期留存不稳定时不宜直接推算很高的终身价值。年付改善收款时间，未来服务成本和退款义务仍存在，不能将年付收款当成当月利润。

9 降本优化的优先级

按收益和实施成本排序

下表工期是小团队的规划估计，需按现有系统调整。节省幅度必须用实际账单验证。

优先级	动作	实施工作量参考	如何评价收益
P0	任务成本账本与按租户预算	2至5人日	账单能按功能与用户归因，异常可及时定位
P0	限额 防刷 并发 任务预算预占	2至5人日	阻止超预算新任务，覆盖工具和在途请求
P1	缩小首版范围与复用成熟组件	需求阶段持续	减少建设人月和长期维护面
P1	模型分流与按需升级	3至10人日	质量相当时的每成功任务成本下降

优先级	动作	实施工作量参考	如何评价收益
P1	上下文与输出控制	2至7人日	有效输入输出减少，关键结果不缺失
P1	重试 去重 取消与循环上限	2至5人日	无价值调用减少，成功率不被误伤
P2	提示词缓存与结果缓存	2至7人日	实际命中扣除写入失效维护后的净节省
P2	存储 日志 数据库和网络治理	2至10人日	账单分项下降，恢复与审计仍达标
P2	免费额度与获客渠道优化	1至4周观察	免费补贴、留存、付费贡献和回收期改善
P3	承诺采购 议价 自部署	先做专项测算	稳定负载下的总成本及回收期达标

模型路由是模型费用的大项

分类、短摘要、字段提取和标准问答可以先用低成本模型或确定性规则处理；困难推理、长文档和高价值任务使用经验证的更强模型。路由器、升级重跑和答案检查本身也会计费，应合并计算。

不要只用模型自己的自信分数判断是否升级。用任务类型、长度、风险级别、结构校验、检索结果和用户反馈建立可观察规则，再通过评估集调整分流比例。对高价值任务，质量和错误处理成本可能比单次 token 费用更重要。

上下文和输出控制

系统提示保持稳定且简洁；只带当前任务需要的历史消息。长对话可以做摘要，但要保留事实与来源，并计入摘要成本。RAG 应检索经过过滤的相关片段，控制数量和长度，不把整库或整份长文档每次塞给模型。

输出按业务交付设计。字段抽取返回必要结构，摘要明确长度；用户确实需要长报告时按产品价值定价。降低最大输出上限不一定降低实际费用，只有实际计费输出减少才节省；过低上限造成截断和重跑可能适得其反。

重试和智能体循环

只重试可恢复错误，设置次数、退避和总预算。区分前端重复点击、任务恢复、模型失败和支付回调，使用幂等任务标识防止重复生成或重复扣费。用户取消后应向上游发出取消并验证实际停止程度，已发生的计算通常无法追回。

智能体每个任务要限制总步骤、工具次数、执行时长和金额；工具失败后应有确定的退出方式。不要让多个代理各自无界尝试，也不要整页网页或整个工具日志反复填充上下文。

缓存收益要计算净值

提示词缓存降低相同输入的处理费用，模型仍会生成输出；结果缓存直接复用答案，能减少整次生成，但需要验证权限、数据版本、时效和命中正确性。两种缓存不能混为一谈。

将稳定公共前缀放在前面，动态问题放后面；按供应商的最小长度、有效期和命中机制验证。写一次但不再复用的内容可能增加费用。结果缓存键需包含租户、权限、资料版本、模型和关键参数，避免跨用户泄露或返回过期答案。[S6]

每月缓存净收益 = 避免的模型成本 - 缓存写入与读取成本 - 缓存存储计算 - 维护和错误处理成本。供应商宣称的输入折扣只覆盖适用输入部分。

异步批处理和错峰

允许延迟的分类、评估、索引和批量内容任务可以使用批处理。OpenAI官方Batch文档列出相对同步API的50%费用折扣和24小时处理窗口，需确认具体模型与端点支持。[\[S23\]](#) 如果只有20%的模型费用适合该折扣，总模型费用的理论降幅约10%，不是全部成本减半。

实时聊天不宜直接改成长时间等待。批任务需有进度、失败恢复、结果有效期和重复提交控制；供应商峰谷价和批处理优惠也不能在没有明文支持时假定可以叠加。

基础设施与工程效率

先清理闲置实例、预览环境、重复数据库和长时间运行的测试任务。静态资源交给CDN，上传下载使用受控直传，应用与数据库尽量同区域，避免大文件在多个服务之间来回转发。数据库先查慢查询、连接池和索引，再升级规格。

对象存储设置分层与生命周期，对原始文件、生成结果和临时文件使用不同保留规则。按故障排查需要采样日志和缩短高费用索引的保留期，保留必要安全与审计记录。降低备份成本必须同时验证可恢复性。[\[S7\]](#)

模板、托管认证和托管数据库常能减少早期维护工时；迁移到更便宜平台时，把迁移成本、运维负担和供应商锁定一起计算。每月省300元却一次投入15,000元，静态回收期50个月，通常不如优先处理更大的成本项。

10 一个完整的降本演算

优化链条

使用每月200,000任务，先假设全部使用Terra且每任务1.10次调用，再逐步修改参数。每一步承接上一步，模型价格与第5节一致。以下是数学情景，必须通过质量测试后才可当作业务节省。

步骤	月模型费 元	相比前一步节省
全部较高价模型 输入2000 输出800	20,944	起点
85%轻量模型与15%较高价模型	4,922	76.5%
输入减至1400 输出减至650	3,836	22.1%
调用系数从1.10降至1.03	3,592	6.4%
输入中30%缓存读 5%缓存写	3,348	6.8%

最后一步假设剩余65%为普通输入，缓存读按普通输入0.1倍、写按1.25倍计费，因此输入有效价格系数为 $0.65 + 0.30 \times 0.1 + 0.05 \times 1.25 = 0.7425$ 。输出不受提示词缓存折扣影响。[\[S1\]\[S2\]](#)

总模型费从20,944元减至约3,348元，减少约84.0%；不能把每一步的百分比直接相加。相对于已经完成模型分流的第6节基准，进一步节省只有约1,574元 / 月，即基准模型费的32.0%，而不是再节省84%。

优化项目是否值得做

假设剩余优化需要8人日、每人日综合成本1,200元，再增加每月200元缓存和观测维护费用，则一次投入9,600元，每月净节省约1,374元，静态回收期约7.0个月。工作量和维护费都是规划参数。

若月任务量只有20,000，按相同比例推算的月模型节省约157元，连新增200元维护费用都覆盖不了。低流量产品应先选低成本、易维护的实现，而非为了每个可能的折扣建设复杂系统。

验收条件

建立固定、分层的业务评估集，覆盖正常、困难、长文档、无答案和权限异常任务。比较任务成功率、事实与引用正确率、关键字段完整率、P50与P95延迟、每成功任务成本、重试率和用户投诉。

可以预设“关键任务准确率不下降、整体成功率下降不超过1个百分点、P95延迟满足产品目标”等内部验收门槛；具体阈值由业务容错度决定，这些不是行业标准。先小流量对照，发现留存、转化或错误处理恶化即回滚，并把补救成本计入比较。

11 不同类型 AI 网站的额外成本

企业知识库与文档问答

RAG 即检索增强生成，完整费用包括文档授权与清洗、解析或OCR、切分、向量生成、索引存储、检索重排、模型回答和增量更新。PDF页数不是 token 数，扫描件与复杂表格的解析成本也不同。

首次导入成本 = 解析/OCR量×相应单价 + 需向量化token量×向量单价 + 工程清洗劳动。持续成本还要加新文件、变更检测、删除同步、权限过滤和检索评估。初期可评估在已有数据库内实现向量检索，只有检索规模、性能或能力确有需要时再引入独立平台。

降本重点是文件哈希去重、只重建变化部分、控制重排数量、缓存稳定查询和缩短答案上下文。多租户隔离和资料权限不能用共享结果缓存直接替代。企业客户还可能要求单点登录、审计、专属部署、服务级别和人工交付，应单独报价。

图片生成

以旧版GPT Image 1 Mini 的1024×1024中等质量输出价0.011美元 / 张演示；官方页面已标注Deprecated，此处用于说明计费方法，不作为新站采购推荐。输入文本或参考图片另计。[S8] 假设每月10,000张输出，单算输出约770元；若每张最终采用图平均生成3张候选，输出费约2,310元，再加输入、编辑、放大、审核、存储与下载。

图片业务应按“用户采用的图片”核算，跟踪候选数、重生成率、分辨率和编辑次数。先做低成本预览、选择后输出高规格，并按清晰的额度规则收费，往往比只找更低的单张价格有效。

视频生成

Sora 2 官方页面标为Legacy，720×1280或1280×720列示价格为0.10美元 / 秒；此处用作按秒计费演示，采购时确认可用版本。[S9] 假设1,000个8秒视频，单次生成费用约5,600元；如果平均要生成3次才得到采用版本，约16,800元，尚未包括其他处理、存储和传输。

视频按模型、分辨率、秒数和候选数分别计量。先验证脚本与关键帧，限定时长和重生成，设置队列与按秒或积分收费；无限次视频套餐的风险显著高于低成本文本任务。

语音和实时交互

语音至少拆成识别、文本推理、合成和连接服务，按各供应商的分钟、音频token或字符计费。双向实时音频的输入输出比例、静音、打断和会话持续时间会改变成本。可使用语音活动检测、及时结束空闲会话、缓存固定播报，并验证打断后的上游实际消耗。

智能体和联网研究

智能体成本 = 全部模型步骤 + 搜索、网页、OCR、浏览器、沙箱等工具 + 结果验证 + 失败补救。假设5次模型调用每次0.05元、3次工具调用每次0.02元，则单任务0.31元，10万任务即3.1万元；这些单价只是演示参数，明显不同于基础聊天模型。

除 token 上限外，要设置步骤、网页数、文件大小、沙箱时长和金额上限。工具返回先筛选再交给模型，能降低输入与后续循环成本；可靠引用与事实核验则应保留。

12 API 和自部署怎样选择

对比的是相同任务质量下的总成本

API费用以调用为主，适合负载不稳定、流量较低、模型变化频繁和缺少推理运维的团队。自部署需要模型可用且满足商业许可，除GPU外还有CPU、内存、网络、镜像、监控、升级、故障恢复、值班与安全成本。

自购还需电力、制冷、机位、折旧、保修和备件；云GPU按整月租赁时，不要把同一GPU费用既记固定费又记到每token边际费。两种方案共享的网站数据库和支付等成本在差额分析里可抵消，在完整预算里仍存在。

临界值与容量同时检验

临界任务量 = 自部署比API增加的固定成本 ÷ API每任务成本与自部署每任务边际成本之差。只有分母为正、模型质量和容量都达标时，这个临界值才有意义。

假设额外固定成本12,000元 / 月，API每任务0.030元，自部署边际费0.006元，则名义临界点为500,000任务 / 月。这不是GPU报价或真实吞吐承诺。

再假设两份推理副本各有实测输出100token / 秒，平均输出500token，可持续负载系数35%，30天的估算容量为 $2 \times 100 \times 35\% \times 2,592,000 \div 500 = 362,880$ 任务。容量低于名义临界点，需要扩容并重新计算固定成本；若要求单副本故障时仍不降级，可承诺容量还会下降。

评估必须使用代表性的输入长度、输出长度、并发和延迟指标；不能用峰值算力或单用户速度代替生产吞吐。稳定基础负载自部署、峰值走API可以研究，但也会增加路由、模型一致性和运维复杂度。

13 中国与海外业务的成本差异

先按市场选择部署

服务市场	主要成本变化	优先控制点
中国大陆为主	境内云与模型、域名和接入资料、短信支付、内容治理	同区域数据路径、人民币计费、适用备案登记和标识
海外为主	海外API与SaaS、国际收款、税费汇兑、本地化支持	用户地区时延、结算费率、出网、数据导出能力
境内外同时经营	两套部署、支付、发布、监控和数据管理	收益能覆盖重复运维时再扩展，减少不必要跨区同步

服务器放在境外不能直接推出面向境内公众服务的其他义务全部消失。使用海外API前，应确认服务商的支持地区、主体资格、网络质量及数据处理条件；选择架构时同时比较成功率和维护成本。

境内上线的适用事项

ICP备案与经营许可需要分开判断。境内互联网信息服务的许可或备案制度与实际业务有关，不宜仅凭“AI网站”或“接入支付”得出证照结论。预算包括资料、接入、展示和变更维护工时；外包代理费与行政事项不是同一费用。[S16]

生成式AI暂行办法针对向境内公众提供相关服务；未面向境内公众的内部研发应用不按该办法直接套算。具有舆论属性或社会动员能力的服务，还需关注相应安全评估与算法备案条件。[S17] 对调用已备案模型的应用，官方公告给出了地方登记路径；使用已备案模型不代表应用方工作自动完成。[S18]

AI生成合成内容标识办法及配套标准已自2025年9月1日实施。应按业务适用性规划界面标识、文件导出、元数据和测试成本，文本、图片、音视频要求不能混同，也不应默认购买所有数字水印产品。[S19]

数据保护和跨境

需要梳理提示词、上传文件、账户、日志、客服和分析SDK的数据流。数据类型、数量、主体和法定例外会影响跨境程序，不是使用任何海外API都一律需要安全评估，也不是小网站就没有数据保护义务。程序豁免与告知、必要性、权限、删除等义务应分别确认。[S20][S21]

相关成本包括数据清单、条款复核、适用的影响评估、敏感字段处理、权限与删除流程、安全测试及投诉处理。按实际工时和外部报价列专项费用；若已计入研发或支持人力，避免再记一遍。企业或敏感数据场景应在签约前专项确认适用要求。

境内常被低估的费用

对象存储除容量外，还需计算请求、公网下行、CDN回源、跨区复制和处理服务；支持的内网路径与外网下载不能按同一费率计算。[S22] 短信按目的地区、类型、计费条数和合同价计量，长短信、失败重发及刷注册可能增加费用。支付和发信按实际主体与渠道报价，不设虚构的全国统一费率。

14 成本监控和预算控制

每个任务至少记录什么

记录维度	建议字段或指标
身份与产品	task_id、tenant_id、脱敏用户标识、套餐、功能
模型计量	供应商、模型版本、服务档位、普通输入、缓存读写、输出
工具与运行	工具次数、媒体秒数、沙箱时长、调用链、重试、取消
质量和体验	任务状态、成功判定、延迟、用户反馈、错误类别
金额与版本	原币金额、预算汇率、价格版本、预占、实际结算、用户扣费

日志默认脱敏，避免为成本分析长期保存完整敏感提示词。每天将应用计量与供应商账单对账；按模型、租户、功能和套餐汇总，排查价格版本、缓存字段和结算延迟导致的差异。

四层限额

分别设置单任务、单用户、单租户和全站预算。发起任务前预占预计最大成本，结束后按实际成本结算并释放余量；并发请求共享同一个原子额度账本，避免同时穿透余额。工具费用、重试、流式输出和已在途任务都需覆盖。

预算动作可按50%提示、80%限制昂贵功能、95%停止非关键新任务做内部初值，最终阈值由业务设定。供应商提醒不一定自动停止服务；Vercel 等平台需要明确配置相应动作，不能把普通邮件告警当作硬上限。

[S10]

周报和月报

每周看支出最高的功能与用户、每成功任务成本、P95任务成本、免费补贴和异常调用。每月看经营支出、付费贡献、CAC、客户批次留存、云资源闲置、数据增长和预计现金可用月数。

比较“本月成本上涨”时，要区分流量增长、任务结构变化、价格变动和效率恶化。例如用户增加50%、成本增加30%可能意味着效率改善，但如果新增客户不付费，商业结果仍可能变差。

15 三十天实施计划

时间	主要动作	可验收交付
第1至3天	定义任务、费用类别、价格版本与账本	每个关键功能可算任务成本，确认计费单位
第4至7天	上限、预占、重试和取消处理	并发不超扣，异常任务可停止，账单可核对
第8至14天	建评估集，优化模型分流与上下文	质量与延迟对照结果，真实成本差额
第15至21天	验证缓存、存储日志、数据库优化	净节省超过维护成本，恢复演练通过
第22至30天	检查免费额度、套餐、获客与留存	套餐贡献表、渠道回收期、下月预算

每项优化记录实施成本、预计月净节省、观察周期、质量门槛和回滚条件。对低流量产品，先完成P0和简单P1；在账单尚小、命中率和负载不稳定时，暂缓复杂缓存、自建平台和长期资源承诺。

推荐启动方式是明确一个文本收费场景，以受控额度验证付费意愿；首月获取真实任务分布，再替换本报告参数。是否扩功能或扩团队，由可重复的客户需求、单位贡献和资金能力共同决定。

16 可直接复用的预算输入清单

输入项	示例或需要填写的值	更新频率
市场与部署	用户国家地区、服务主体、数据位置	上线前及变化时
用户分组	免费、基础、高级、企业的月活与付费率	每月
任务分布	各功能次数、成功率、P95成本	每周
模型计量	各模型输入输出、缓存读写、调用放大	每周
云用量	请求、CPU、数据库、存储、出网、日志	每周
价格条件	型号、区域、币种、阶梯、优惠到期	采购前及每月
人力投入	建设、维护、客服、增长实际工时	每月
收款与增长	净收入、退款、支付、CAC、客户留存	每月
资金安排	一次性建设、预付、现金余额、缓冲	每月

每次更新按同样顺序计算：各类用户任务量，再算各任务变量费；加固定交付和经营费用；最后加入实际支付、税费、一次性费用与预算缓冲。比较收入时使用一致的净额口径，支付手续费只扣一次。

下一次预算应至少能回答：一个成功任务花多少钱，一位付费用户补贴多少免费用户，哪个功能最耗钱，哪项优化能最快回收投入，以及当前现金能维持多久。

17 官方来源与核价说明

以下链接对应文中的编号。核查日期统一为2026年9月13日；动态页面可能调整价格或型号。采购时再次核对账号内计费规则，模型版本变化后重新跑质量评估。人力、固定资源额度、汇率、转化率、任务量、工期与优化回报均为本报告明示的规划参数。

[S1] OpenAI GPT 5.6 Luna 模型及定价

[S2] OpenAI GPT 5.6 Terra 模型及定价

[S3] DeepSeek 中文模型定价与峰谷规则

[S4] Anthropic Claude API 定价

[S5] OpenAI API 完整定价及处理档位

[S6] OpenAI 提示词缓存与读写计量

[S7] AWS EC2 按需计费与数据传输

[S8] OpenAI GPT Image 1 Mini 图像计费

[S9] OpenAI Sora 2 视频计费

[S10] Vercel Spend Management 预算动作

[S11] Cloudflare Workers 官方计费

[S12] Cloudflare R2 官方计费

[S13] Supabase 官方定价

[S14] Vercel 官方定价

[S15] Stripe 美国标准定价

[S16] 工信部 互联网信息服务管理办法

[S17] 国家网信办 生成式人工智能服务管理暂行办法

[S18] 国家网信办 2026年生成式人工智能服务备案信息公告

[S19] 国家网信办 人工智能生成合成内容标识办法

[S20] 国家网信办 促进和规范数据跨境流动规定

[S21] 网络数据安全条例

[S22] 阿里云 OSS 计费项目

[S23] OpenAI Batch API 异步批处理